Как устроена векторизация поведения пользователя

Как устроена векторизация поведения пользователя

Индустриальный подход (BioCatch, IBM Trusteer, Capital One, Cleafy) сводится к одной схеме: первый шаг — сбор данных для построения профиля нормального поведения каждого пользователя. Данные собираются пассивно, пока пользователь взаимодействует с приложением. Для создания точного базового профиля требуется минимум 8 сессий. Затем каждую сессию система непрерывно сравнивает текущее поведение с историческим профилем и выдаёт оценку вероятности того, что действия совершает легитимный пользователь.

Из одной сессии можно извлечь порядка 2 000 различных элементов — этого достаточно, чтобы с высокой уверенностью определить, что это именно ваш конечный пользователь.

Технически, как показывает работа Capital One, последовательность цифровых сессий кодируется через seq2seq автоэнкодеры, а затем моделируется совместно с временным и финансовым контекстом для полного представления скрытых намерений пользователя.

Для Альфа-Бизнеса я предлагаю **42 сырых метрики**, сгруппированных в 7 слоёв. Каждая метрика агрегируется по сессии, нормализуется, и из полного вектора формируется эталонный профиль (через скользящее среднее по последним N сессиям). Затем `vector_cosine_dist` — это просто `1 - cosine_similarity(текущий_вектор, эталон)`, а `behavior_cluster_shift` — евклидово расстояние до центроида кластера данного пользователя.

Слой 1 — Временной ритм (6 метрик)

Отвечает на вопрос: **«В какое время и как часто этот человек работает?»**

#	Колонка	Тип	Что собирает	Роль в векторе
1	`session_start_hour`	float	Час начала сессии (0–23.99)	У каждого пользователя свой «рабочий час». Директор заходит в 9:00, бухгалтер — в 7:30. Отклонение от привычного часа → рост cosine_dist
2	`session_day_of_week`	int	День недели (0=Пн, 6=Вс)	Работа в выходные для директора нетипична, для бухгалтера перед дедлайном — норма

#	Колонка	Тип	Что собирает	Роль в векторе
3	`session_duration_sec`	float	Длительность сессии в секундах	Владелец сидит 3–5 минут (подписал — ушёл), бухгалтер — 20–40 минут
4	`inter_session_gap_hours`	float	Время между текущей и предыдущей сессией	Резкое сокращение (стало 2 часа вместо обычных 24) — маркер передачи учётки
5	`sessions_per_day_rolling7`	float	Среднее число сессий в день за 7 дней	Стабильная частота = один пользователь, скачки = несколько людей
6	`is_off_hours`	bool	Вход в нерабочее время (22:00–06:00)	Сильный аномальный сигнал, если раньше никогда не было ночных заходов

Слой 2 — Навигационный почерк (7 метрик)

Отвечает на вопрос: **«Как именно человек ходит по разделам?»**

#	Колонка	Тип	Что собирает	Роль в векторе
7	`pages_visited_count`	int	Количество посещённых страниц за сессию	Глубина сессии, один из ключевых элементов вектор
8	`unique_sections_visited`	int	Количество уникальных разделов (Счета, Платежи, Выписки, Контрагенты и т.д.)	Низкое значение 2) = целевой визи или бот
9	`section_sequence_hash`	cat→emb	Хеш последовательности посещённых разделов	Кодируется через embedding (аналс Word2Vec для страниц). Каждый раздел = «слово» сессия = «предложение». Позволяет сравнивать маршруты
10	`first_section_visited`	cat→onehot	Первый раздел после входа	Директор → Главная, бухгалте → Выписки,

#	Колонка	Тип	Что собирает	Роль в векторе
				атакующий → Платежи
11	`time_to_first_action_sec`	float	Время от входа до первого клика	Опытный пользователь кликает за 2–3 се новичок — 10+
12	`mean_time_per_page_sec`	float	Среднее время на одной странице	Длинные просмот = чтение/проверка короткие = автоматизирован действия
13	`bounce_rate_sections`	float	Доля разделов, в которых пользователь был менее 3 сек	Высокий bounce - «сканирование» интерфейса, характерно для нового пользоват

Слой 3 — Операционный профиль (8 метрик)

Отвечает на вопрос: **«Что человек делает с деньгами и документами?»**

#	Колонка	Тип	Что собирает	Роль в векторе
14	`payments_created_count`	int	Число созданных платежей за сессию	Определяет ролевой кластер: много = операционист, мало = директор
15	`payments_signed_count`	int	Число подписанных платежей	В сочетании с created даёт sign_ratio
16	`total_amount_signed`	float (log)	Суммарный объём подписанных платежей (log-transform)	Аномальные суммы → рост cosine_dist
17	`median_payment_amount`	float (log)	Медианная сумма одного платежа	Устойчивая характеристика «калибра» пользователя
18	`counterparties_count`	int	Число уникальных контрагентов за сессию	Много новых = потенциальный fraud-паттерн
19	`new_counterparty_flag`	bool	Были ли платежи новым контрагентам	Бинарный сигнал для быстрой детекции
20	`imports_count`	int	Число импортов реестров	Импорт = бухгалтерская операция, директор этого не делает

#	Колонка	Тип	Что собирает	Роль в векторе
21	`statements_downloaded`	int	Число скачиваний выписок	Типичный маркер бухгалтера/аудитора

Слой 4 — Взаимодействие с интерфейсом (6 метрик)

Отвечает на вопрос: **«Как человек физически взаимодействует с системой?»** Именно здесь живёт behavioral biometrics.

#	Колонка	Тип	Что собирает	Роль в векторе
22	`click_rate_per_min`	float	Частота кликов в минуту	Поведенческая биометрика анализирует, как пользователи взаимодействуют с экраном — касания, движения мыши, набор текста — и строит детальные поведенческие профили
23	`scroll_speed_avg`	float	Средняя скорость скролла (px/sec)	Индивидуальная привычка, сложно подделать
24	`mouse_movement_entropy`	float	Энтропия траекторий мыши	Ботоподобные движения → низкая энтропия
25	`form_fill_speed_cps`	float	Скорость заполнения форм (символов/сек)	Паттерны нажатий клавиш включают скорость набора, ритм и используемые сочетания клавиш
26	`copy_paste_ratio`	float	Доля полей, заполненных через copy-paste	Бухгалтеры часто вставляют ИНН/КПП из файла, директоры — нет
27	`idle_gaps_count`	int	Число пауз > 30 сек внутри сессии	Много пауз = «под диктовку» (социальная инженерия) или параллельная работа

Слой 5 — Устройство и сеть (7 метрик)

Отвечает на вопрос: **«С какого устройства и откуда пришёл?»**

#	Колонка	Тип	Что собирает	Роль в векторе
28	`device_type`	cat→onehot	Тип устройства (desktop/mobile/tablet)	Резкая смена типа → другой человек
29	`os_version_hash`	cat→emb	Хеш ОС+версия	Стабильный отпечаток
30	`browser_fingerprint_hash`	cat→emb	Хеш browser fingerprint (разрешение, шрифты, язык, плагины)	Главный технический идентификатор
31	`screen_resolution`	cat→onehot	Разрешение экрана	1920×1080 в офисе vs 1440×900 дома
32	`ip_subnet_hash`	cat→emb	Хеш /24 подсети IP	Один офис = один хеш, дом = другой
33	`geo_city`	cat→emb	Город по IP	Стабильная геолокация = один пользователь
34	`is_vpn_detected`	bool	Детекция VPN/proxy	VPN сам по себе не аномалия, но в сочетании с другими сигналами усиливает

Слой 6 — Контекст и сезонность (4 метрики)

Отвечает на вопрос: **«Какие внешние условия объясняют активность?»**

#	Колонка	Тип	Что собирает	Роль в векторе
35	`is_tax_deadline_window`	bool	Попадает ли сессия в окно ±5 дней от налогового дедлайна	Снижает вес аномалий (бухгалтер работает ночью — это нормально в налоговый период)
36	`is_payroll_window`	bool	Окно начисления зарплаты (25–5 числа)	Объясняет пиковую активность бухгалтеров

#	Колонка	Тип	Что собирает	Роль в векторе
37	`days_since_account_creation`	int	Возраст аккаунта в днях	Молодые аккаунты = менее стабильный профиль, требуется больше порог
38	`total_sessions_lifetime`	int	Общее число сессий за всё время	Контролирует «зрелость» вектора — при < 8 сессиях профиль ещё не калиброван

Слой 7 — Межсессионная динамика (4 метрики)

Отвечает на вопрос: **«Как поведение меняется от сессии к сессии?»**

#	Колонка	Тип	Что собирает	Роль в векторе
39	`rolling_vector_stability_7d`	float	Стандартное отклонение cosine_dist за последние 7 дней	Стабильный = один человек, «прыгающий» = двое под одной учёткой
40	`section_pattern_change_rate`	float	Доля новых навигационных паттернов за последние 5 сессий	Резкое появление новых маршрутов = смена оператора
41	`device_switch_frequency_30d`	float	Частота смены устройств за 30 дней	У одного человека 1–2 устройства, при шаринге — 3+
42	`concurrent_session_flag`	bool	Есть ли параллельная активная сессия	Самый простой и надёжный признак: под учёткой сидят минимум двое

Как из этих 42 колонок получается вектор

Процесс в 4 шага:

Шаг 1 — Агрегация по сессии. Каждая сессия превращается в вектор из ~42 числовых значений. Категориальные признаки кодируются через learned embeddings (обучаемые в рамках автоэнкодера) или one-hot.

Шаг 2 — Формирование эталона. Эталонный вектор пользователя = экспоненциально-взвешенное скользящее среднее по последним 30 сессиям. Свежие сессии имеют больший

вес. Хранится в Data Lake как `user_reference_vector`.

Шаг 3 — Вычисление метрик. Для каждой новой сессии:

- `vector_cosine_dist = 1 - cosine_similarity(session_vector, user_reference_vector)` — единое число отклонения
- `behavior_cluster_shift = euclidean_distance(session_vector, cluster_centroid)` — расстояние от центра кластера, построенного через K-Means по историческим сессиям. Если пользователь «раздваивается», появляется два кластера, и shift растёт для обоих

Шаг 4 — Обновление. Если сессия признана нормальной (класс 0), эталонный вектор обновляется. Если аномальная — не обновляется, чтобы не «отравить» профиль. Для мониторинга дрифта модели используется отслеживание распределения косинусных расстояний между новыми и старыми представлениями каждого пользователя.

Практические заметки для Альфа-Бизнеса

Что уже доступно без доработок: колонки 1–6, 7–8, 10–21, 28–34, 35–38, 42 — эти данные либо уже есть в логах веб-сервера и системе ДБО, либо извлекаются из стандартных HTTP-заголовков и clickstream.

Что требует JS-трекера на фронтенде: колонки 22–27 (click rate, scroll speed, mouse entropy, form fill speed, copy-paste ratio, idle gaps) — это behavioral biometrics, собирается через лёгкий JavaScript SDK, внедрённый в интерфейс Альфа-Бизнеса. Когда паттерны сравниваются между несколькими сессиями, система узнаёт, как именно ведёт себя данный пользователь, и строит поведенческий профиль, а затем мониторит каждую последующую сессию.

Минимальная «зрелость» профиля: первые 8–10 сессий система работает в режиме обучения (только собирает данные, не выдаёт аномалии). После этого вектор калиброван и начинает работать на детекцию.

Источники

1. https://www.ibm.com/think/topics/behavioral-biometrics — IBM, про сбор данных для профиля и минимум 8 сессий, паттерны клавиатуры
2. https://www.onespan.com/topics/behavioral-biometrics — OneSpan, про непрерывное сравнение с историческим профилем и scoring
3. https://www.bai.org/banking-strategies/the-fraud-prevention-use-case-for-behavioral-biometrics/ — BAI/BioCatch, про 2 000 извлекаемых элементов из одной сессии
4. https://www.capitalone.com/tech/machine-learning/dynamic-customer-embeddings-sequential-recommendation-representation-learning/ — Capital One, про seq2seq автоэнкодеры и мониторинг дрифта через cosine distance

5. https://www.cleafy.com/insights/how-behavioral-biometrics-can-help-you-fight-online-banking-fraud — Cleafy, про анализ касаний, мыши и набора текста для построения профилей
6. https://www.getfocal.ai/blog/behavioral-biometrics — Focal, про сравнение паттернов между сессиями и непрерывный мониторинг