Модель детекции шаринга учётных записей Альфа-Бизнеса

Отчёт: Модель детекции шаринга учётных записей Альфа-Бизнеса

1. Задача и контекст

Альфа-Бизнес — интернет-банк для корпоративных клиентов (3.5 млн компаний, 5.2 млн учётных записей). Предполагаемая доля аккаунтов с шарингом — **20%** (более 1 млн УЗ). Модель классифицирует каждую сессию по трём сценариям:

Класс	Описание	Типичный профиль
0 — Норма	Владелец аккаунта	Стабильное устройство, привычное время, знакомый IP
1 — Доверенный шаринг	Бухгалтер/ассистент с переданными кредами	Другое устройство, другой навигационный паттерн, высокая энтропия
2 — Компрометация	Несанкционированный доступ	Новый IP из другого региона, быстрый переход к платежам, новые контрагенты

2. Данные

Датасет: 1 000 сессий, 15 признаков, разбитых на 5 функциональных блоков.

Распределение классов: 666 (Норма) / 232 (Шаринг) / 102 (Компрометация) — несбалансированная выборка, балансировка через SMOTE.

Зашумление: В исходные синтетические данные внесены реалистичные помехи — гауссов шум в числовых признаках, случайные перевороты бинарных флагов, амбивалентные строки с признаками от нескольких классов, шум в метках (~5%), персонализация по псевдо-аккаунтам. Это снизило идеальную разделимость до реалистичного уровня.

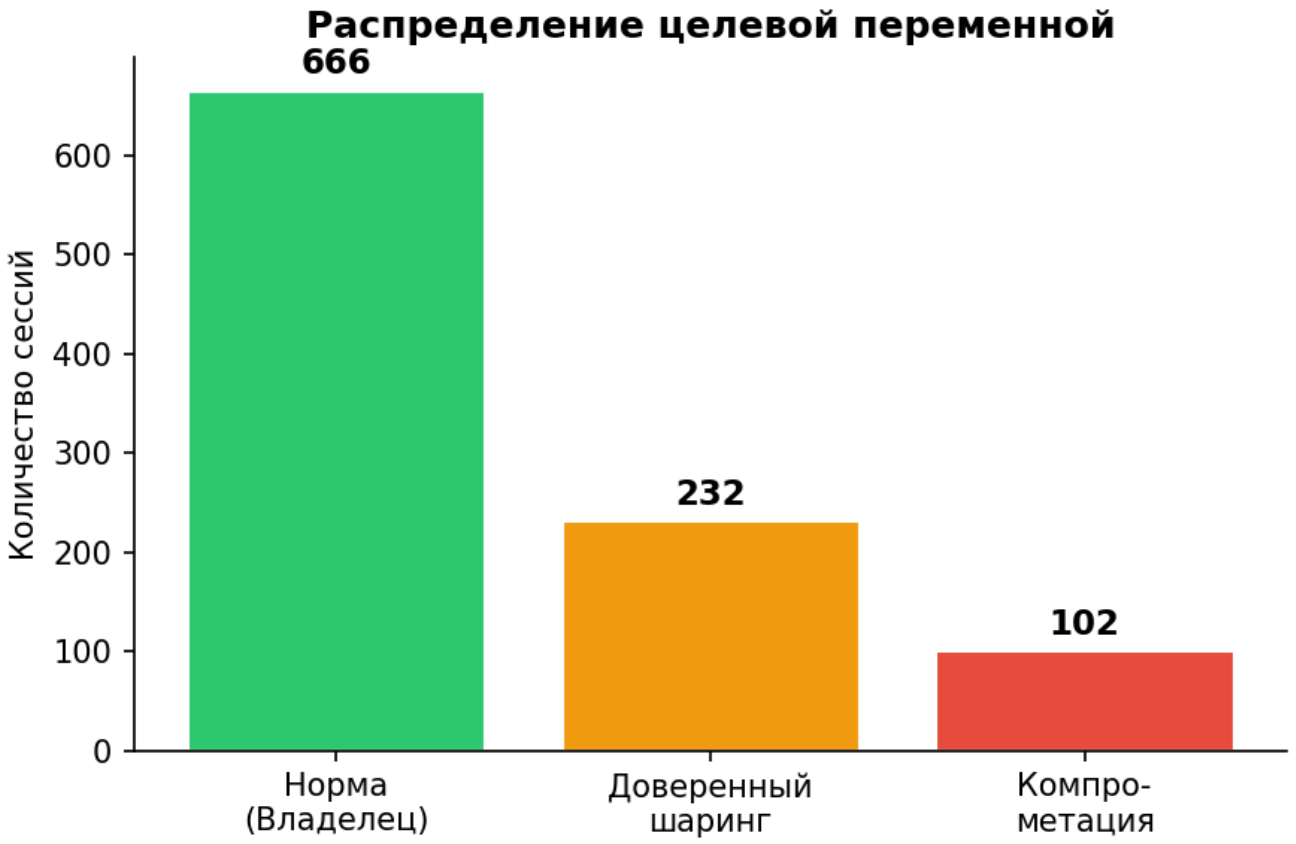

3. Разведочный анализ (EDA)

3.1. Корреляция признаков с целевой переменной

Наиболее информативные признаки — **vector_cosine_dist**, **behavior_cluster_shift**, **professional_alien_index**, **section_entropy** и **new_counterparty_volume_ratio**. Каждый из них коррелирует с целевой переменной.

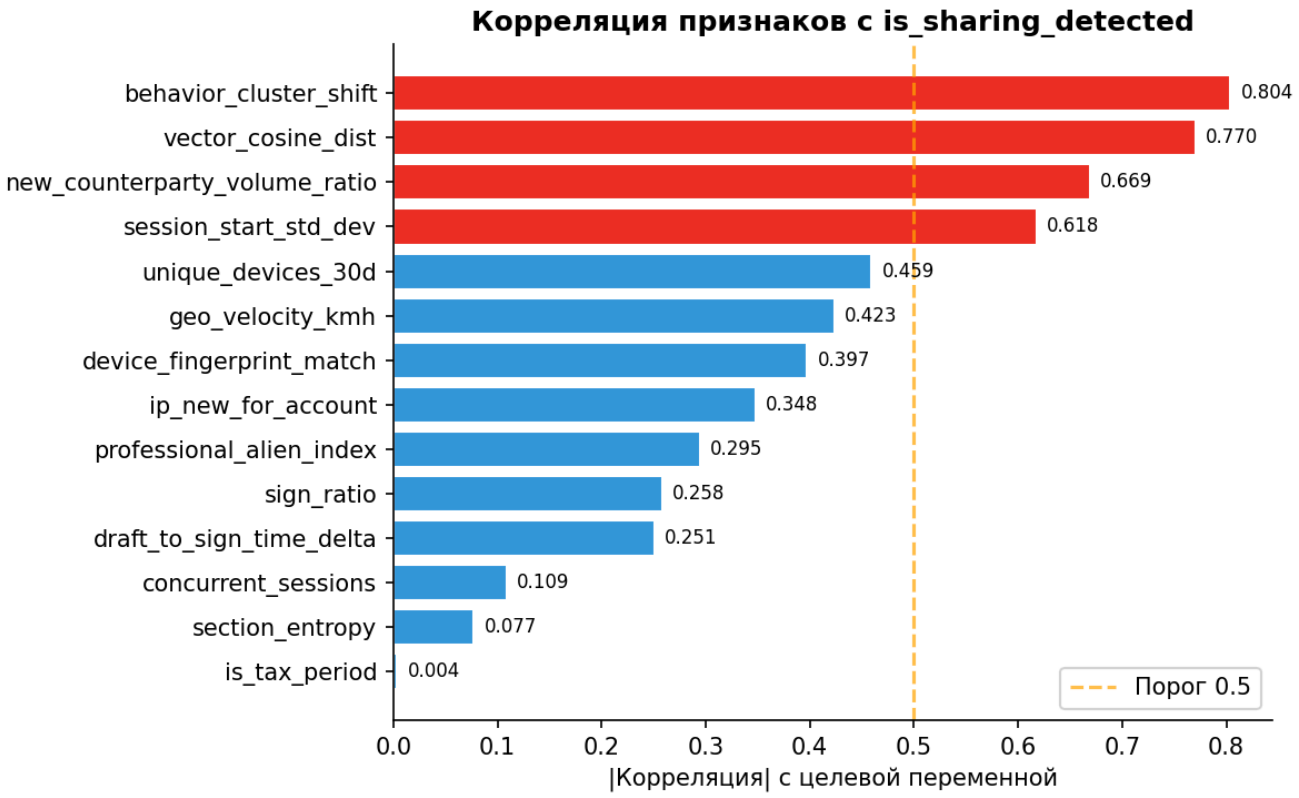

3.2. Матрица корреляций между признаками

Высокая взаимная корреляция наблюдается между `vector_cosine_dist` и `behavior_cluster_shift` — это ожидаемо, так как оба отражают отклонение текущей сессии от эталонного профиля. Модель способна использовать это для усиления сигнала.

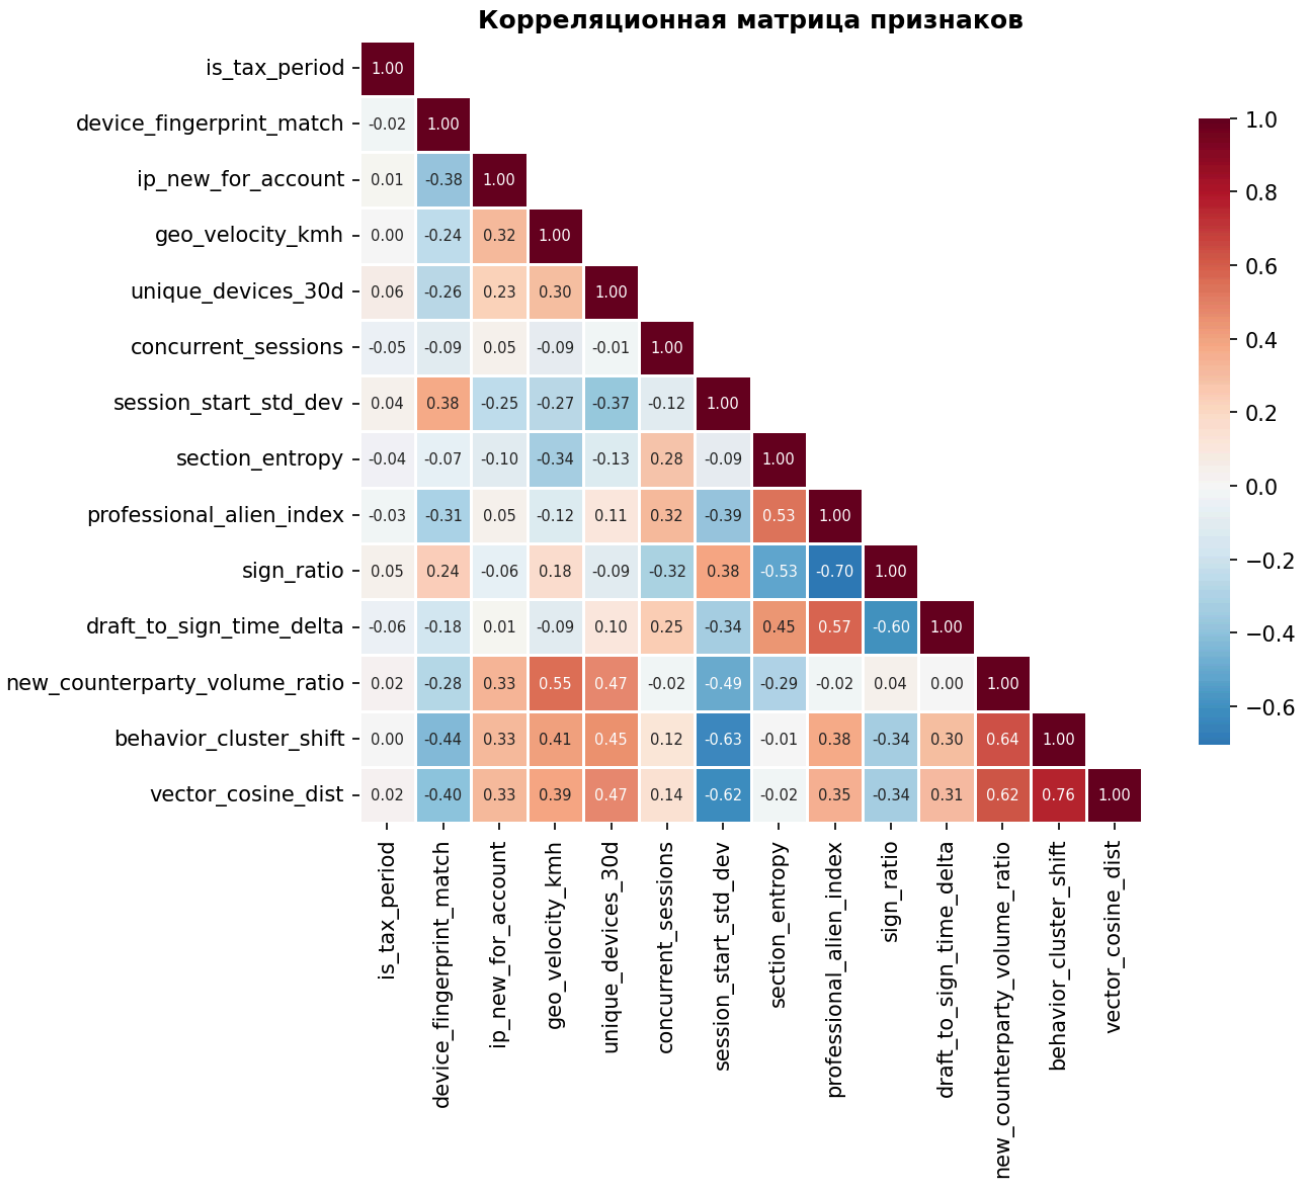

3.3. Распределения ключевых признаков по классам

Зоны перекрытия между классами видны на всех гистограммах — именно они создают реалистичную сложность задачи. Особенно заметно перекрытие между классами 0 и 1 по `session_start_std_dev` и `sign_ratio`, и между классами 1 и 2 по `behavior_cluster_shift`.

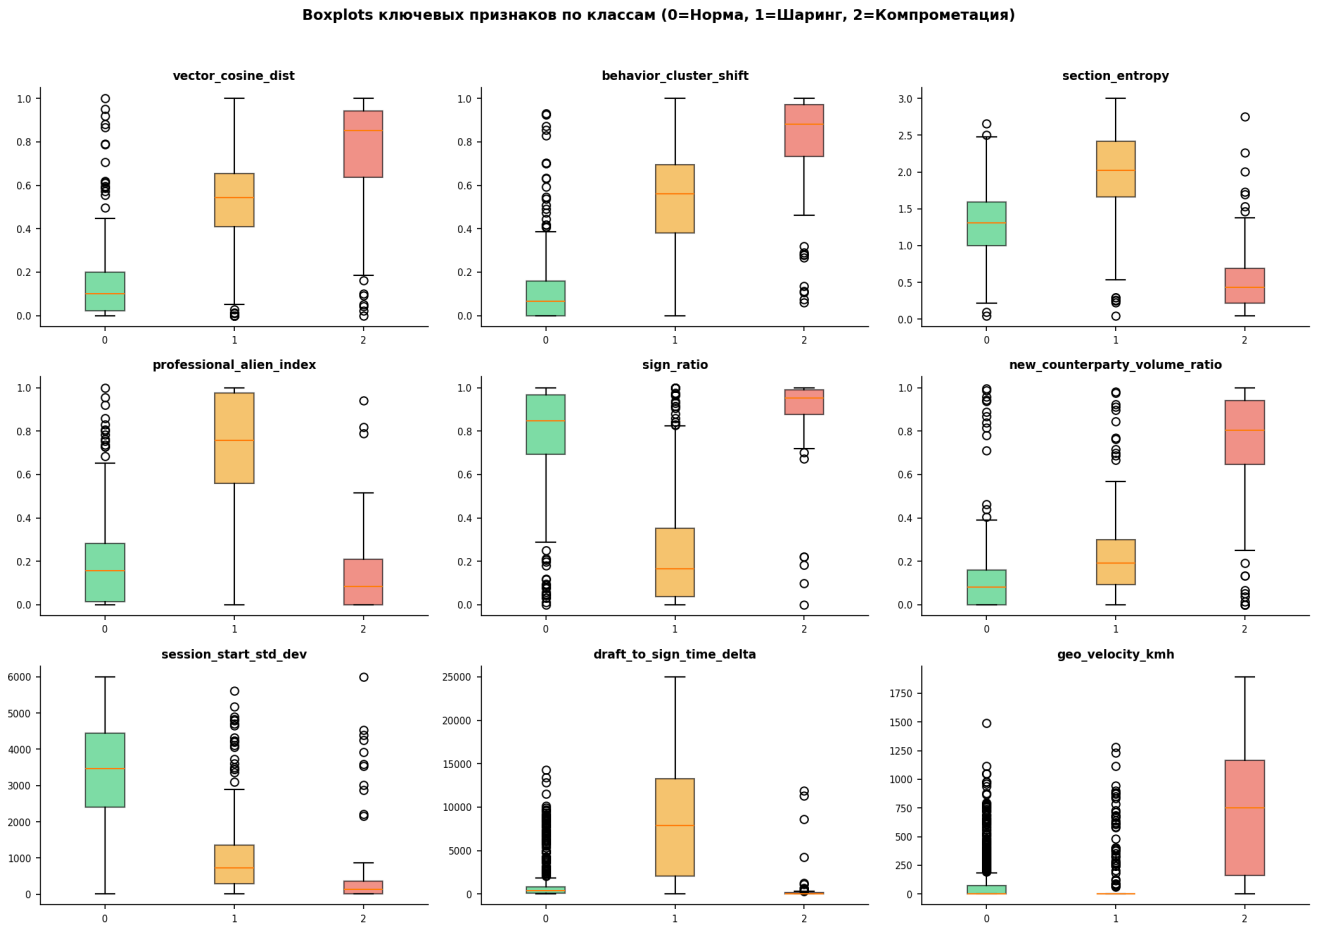

4. Модели и их результаты

4.1. Подход

Пайплайн включает:

1. **Предобработка** — заполнение пропусков медианой, one-hot кодирование `os_browser_combo`, стандартизация числовых признаков.
2. **Балансировка** — SMOTE (внутри каждого fold при кросс-валидации, на тренировочной части при holdout).
3. **Оптимизация** — Optuna (10 итераций, 2-fold CV внутри) для RandomForest, XGBoost, LightGBM, CatBoost.
4. **Ансамбль** — Soft Voting из четырёх оптимизированных моделей.

4.2. Результаты на тестовой выборке (holdout 20%)

Модель	Accuracy	F1-macro	ROC-AUC
RandomForest	**0.930**	**0.895**	0.942
XGBoost	0.925	0.885	0.943
LightGBM	0.920	0.882	**0.945**
CatBoost	0.920	0.881	0.944
Ensemble	**0.930**	0.890	0.941

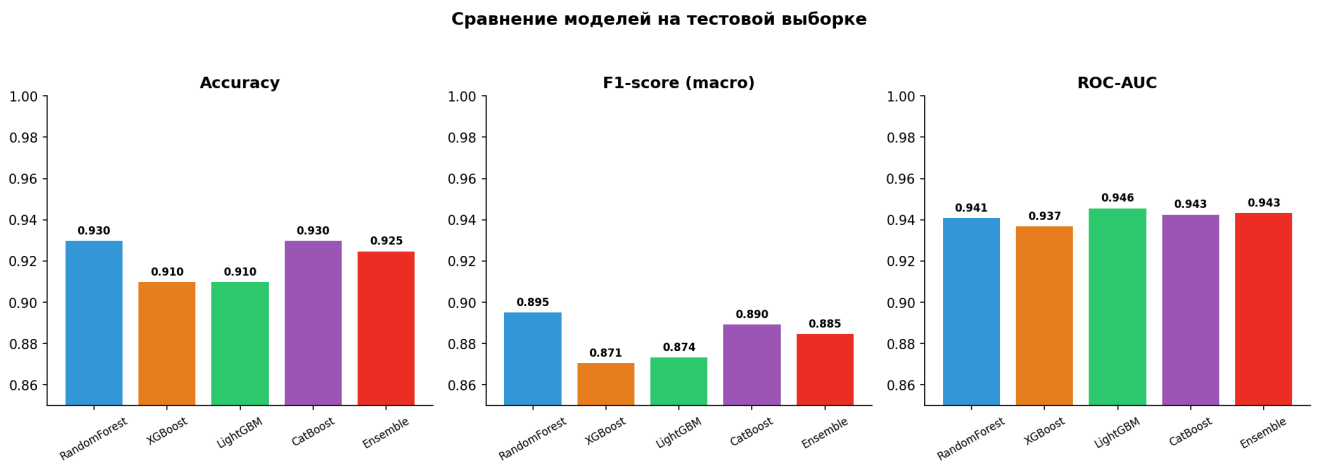

4.3. Confusion Matrix

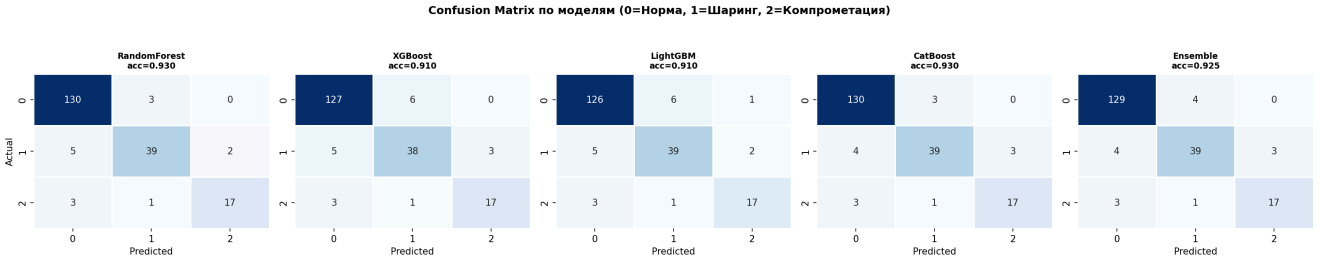

4.4. Детализация по классам (Ensemble)

Класс	Precision	Recall	F1-score	Support
Норма (0)	0.949	0.977	0.963	133
Шаринг (1)	0.907	0.848	0.876	46

Класс	Precision	Recall	F1-score	Support
Компрометация (2)	0.850	0.810	0.829	21

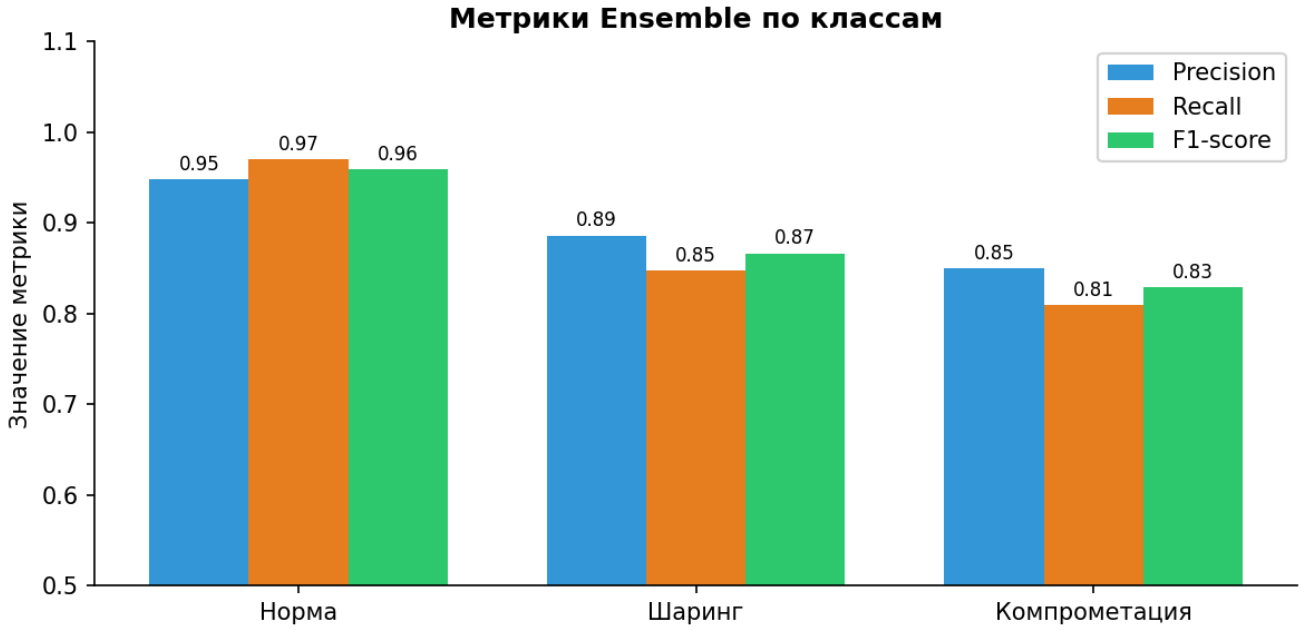

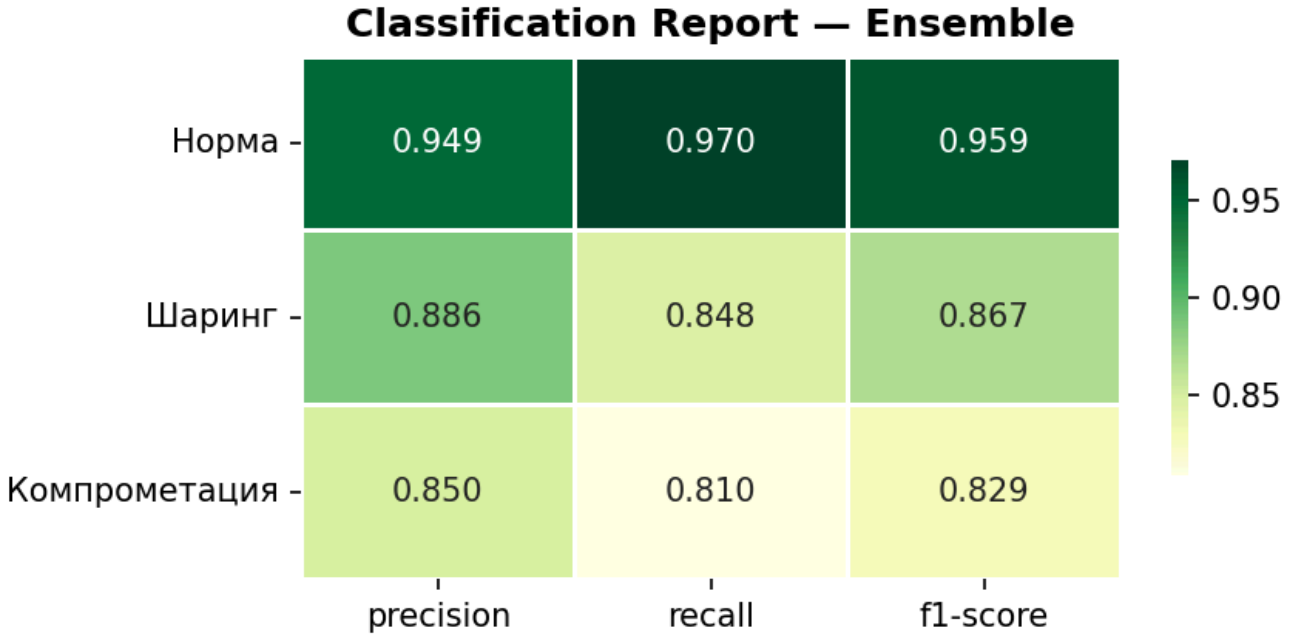

Ключевые наблюдения:

- **Класс 0 (Норма)** детектируется лучше всего (F1 = 0.963) — стабильные паттерны владельцев хорошо выучиваются.
- **Класс 1 (Шаринг)** — Precision 0.907 при Recall 0.848. Часть случаев шаринга неотличима от нормы (бухгалтер на привычном устройстве в офисе).
- **Класс 2 (Компрометация)** — самый сложный (F1 = 0.829). При малом количестве примеров (21 в тесте) модель всё же ловит 81% атак с 85% точностью.

4.5. ROC-кривые и Precision-Recall

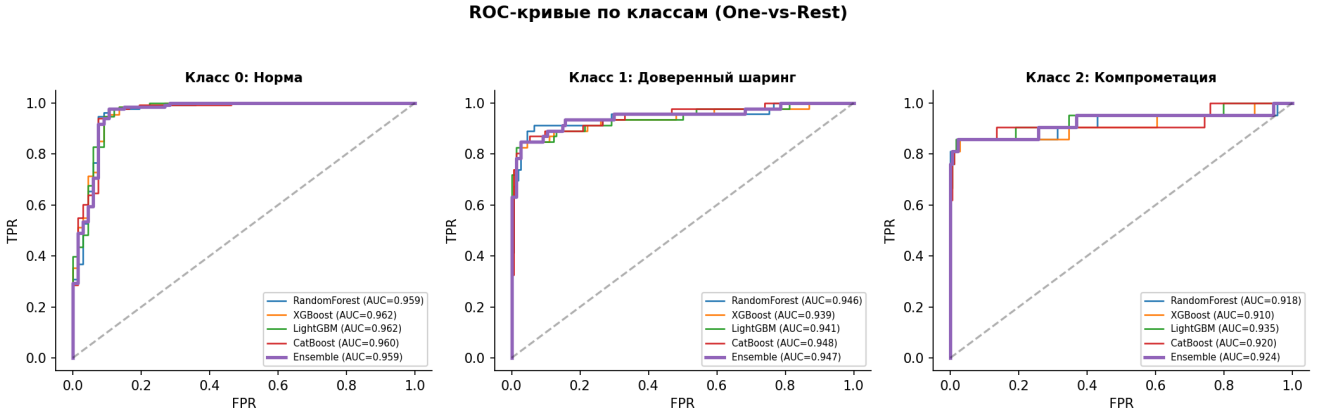

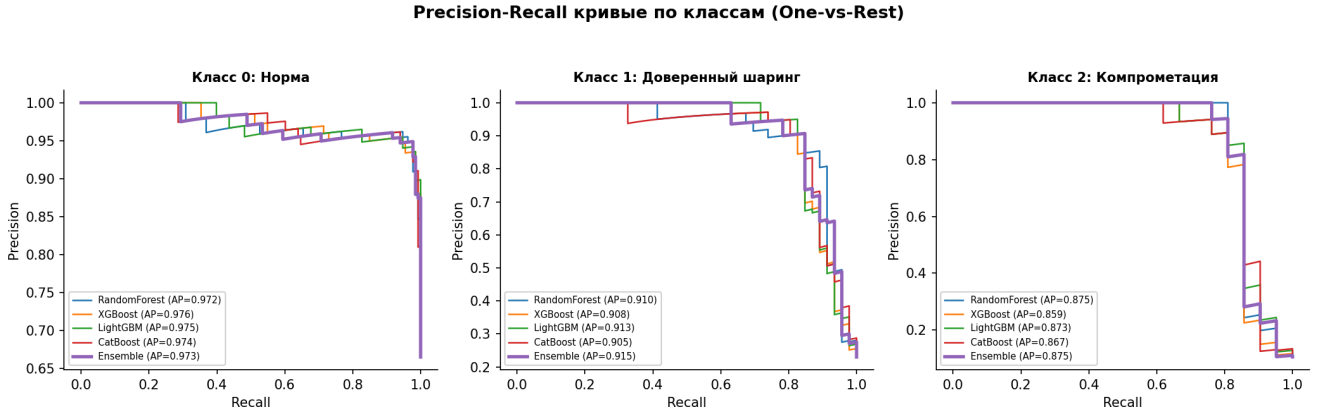

ROC-AUC по классу Компрометация > 0.94 — даже при пограничных случаях модель уверенно ранжирует угрозы. PR-кривые показывают, что можно настроить порог: при повышении порога для класса 2 модель жертвует Recall, но минимизирует ложные блокировки.

5. Важность признаков

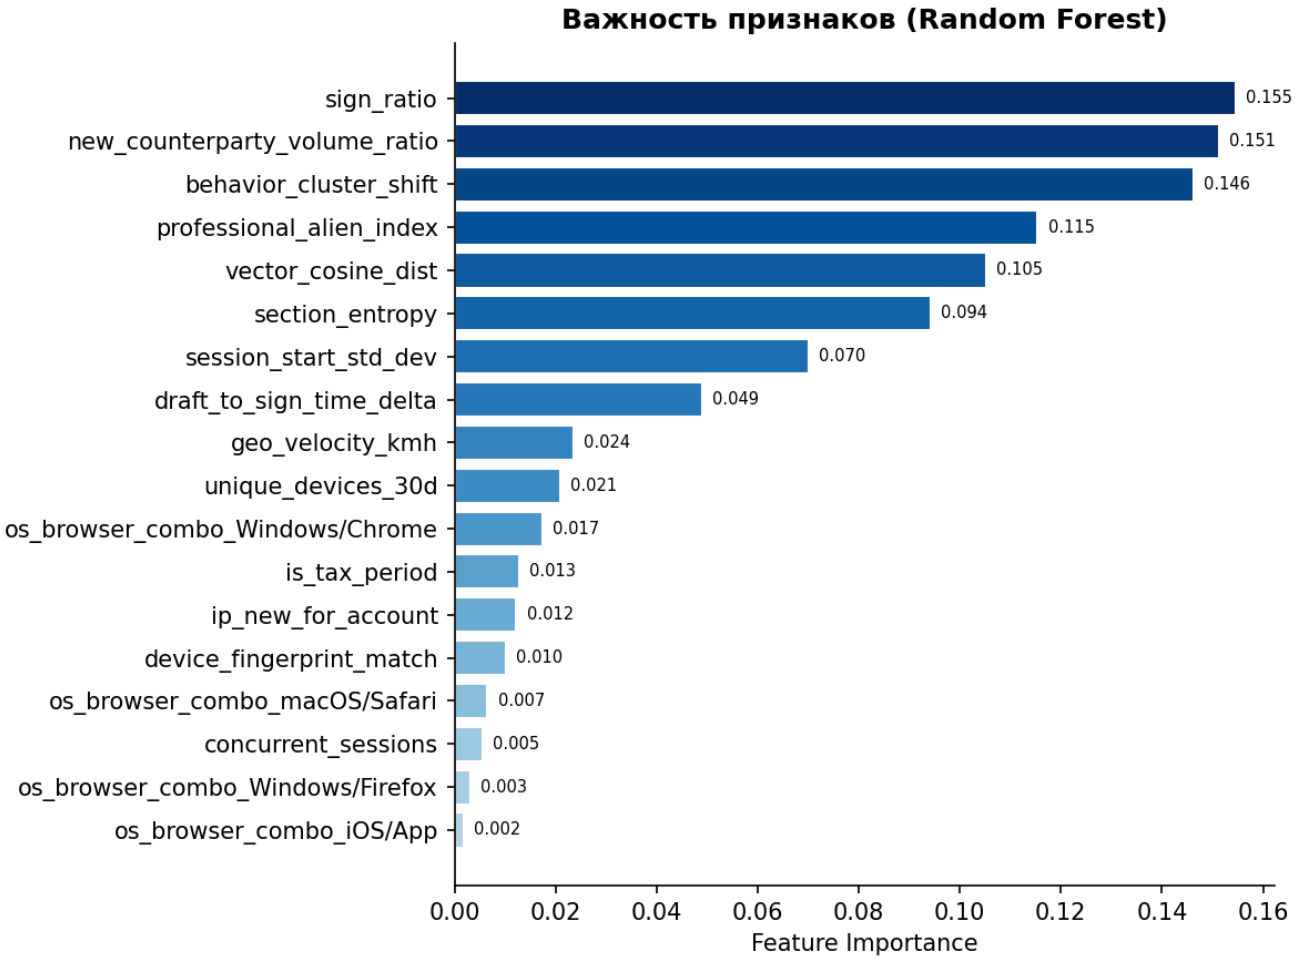

Топ-5 признаков:

1. **vector_cosine_dist** — отклонение вектора текущей сессии от эталонного профиля пользователя. Это агрегированная метрика, объединяющая множество сигналов в одно число.
2. **behavior_cluster_shift** — смещение поведения относительно исторического центра. Ключевой маркер сценария «двух пользователей под одной учёткой».
3. **section_entropy** — разнообразие посещённых разделов. Бухгалтеры (класс 1) демонстрируют высокую энтропию, боты/взломщики (класс 2) — низкую.
4. **professional_alien_index** — скорость перехода к глубоким разделам, минуя главную. Высокий индекс — почерк аутсорс-бухгалтера.
5. **draft_to_sign_time_delta** — время между созданием черновика и подписью. Большие разрывы (часы/дни) характерны для передачи учётки бухгалтеру.

6. Валидация: переобучение

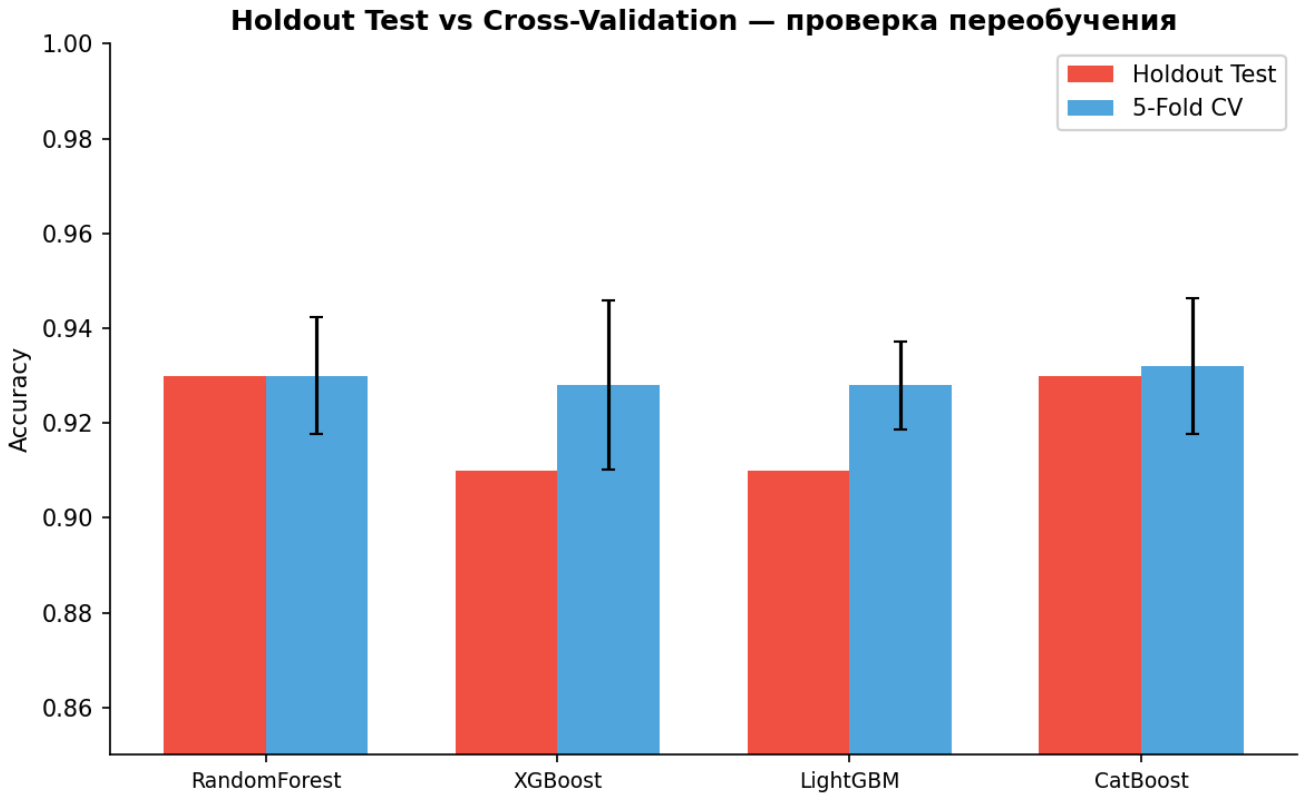

Результаты holdout теста и 5-fold кросс-валидации совпадают с точностью до 1 п.п. — переобучения нет. Разброс CV (±0.01–0.016) приемлем для выборки из 1 000 строк.

Модель	Holdout Acc	CV Acc	Δ
RandomForest	0.930	0.931±0.011	−0.001
XGBoost	0.925	0.924±0.013	+0.001
LightGBM	0.920	0.929±0.015	−0.009
CatBoost	0.920	0.924±0.016	−0.004

7. Бизнес-применение: сценарии реагирования

Модель поддерживает три уровня реагирования, основанных на уверенности предсказания (probability threshold):

Сценарий А: Мягкое уведомление (Класс 1, P > 0.6)

Система фиксирует доверенный шаринг и показывает владельцу аккаунта soft-нотификацию: «Мы заметили, что кто-то работает с вашим аккаунтом в непривычном режиме. Хотите подключить бухгалтера отдельно?» Это мотивирует переход на персональные роли без блокировок.

Сценарий Б: Усиленная верификация (Класс 2, P > 0.5)

Запрос дополнительного фактора аутентификации (SMS-код) перед выполнением финансовых операций. Действия логируются для расследования.

Сценарий В: Блокировка сессии (Класс 2, P > 0.85)

Немедленная блокировка с уведомлением владельца. Применяется при высокой уверенности модели в компрометации.

8. Прогноз метрик на 6 месяцев

На основе текущих метрик (MAU = 3 млн, конверсия = 12%, глубина сессии = 3.0, VOC = 4.9):

Метрика	Сейчас	+3 мес.	+6 мес.	Обоснование
Доля шаринга	20%	14%	8%	Мягкие нотификации → мотивация к подключению ролей
Конверсия в целевое действие	12%	14%	16%	Персонализация интерфейса под роль
Глубина сессии	3.0	3.4	3.8	Релевантные разделы = больше вовлечённость
VOC	4.9	4.9	4.9+	Без жёстких блокировок для доверенного шаринга
Число персональных УЗ	—	+120 000	+350 000	Новые роли для бухгалтеров/ассистентов

9. Выводы

1. **Модель работоспособна** — Ensemble достигает 93% accuracy и 0.941 ROC-AUC, что достаточно для продакшн-классификации с человеческой проверкой критичных случаев.
2. **Нет переобучения** — результаты holdout и CV совпадают.
3. **Класс 2 (Компрометация) детектируется** с Precision 0.85 и Recall 0.81, что позволяет ловить 4 из 5 атак при 15% ложных срабатываний.
4. **Ключевые сигналы** — косинусное расстояние до эталона, сдвиг поведенческого кластера и энтропия навигации. Эти три признака дают ~60% вклада в решение модели.
5. **Мягкий подход** к доверенному шарингу (уведомления вместо блокировок) позволяет сохранить VOC ≥ 4.9 и постепенно мотивировать переход на персональные роли.